Programmazione iterativa

Programmazione iterativa

Il concetto di iterazione è alla base di qualsiasi operazione nei linguaggi di programmazione. In R molte delle operazioni sono vettorizzate. Questo rende il linguaggio più efficiente e pulito MA nasconde il concetto di iterazione.

Ad esempio la funzione `sum()` permette di sommare un vettore di numeri.

```
# somma i numeri da 1 a 10
sum(1:10)
```

```
[1] 55
```

Ma cosa si nasconde sotto?

Esempio: se io vi chiedo di usare la funzione `print()` per scrivere “hello world” nella console 5 volte, come fate?

```
msg = "hello world"
print(msg)
```

```
[1] "hello world"
```

```
print(msg)
```

```
[1] "hello world"
```

```
print(msg)
```

```
[1] "hello world"
```

```
print(msg)
```

```
[1] "hello world"
```

```
print(msg)
```

```
[1] "hello world"
```

Quello che ci manca (e che invece fa la funzione `sum()`) è un modo di ripetere una certa operazione, senza effettivamente ripetere il codice manualmente.

Ci sono vari costrutti che ci permettono di ripetere operazioni, i più utilizzati sono:

- Ciclo `for`
- Ciclo `while`
- Ciclo `repeat`
- `*apply` family

Il ciclo `for`

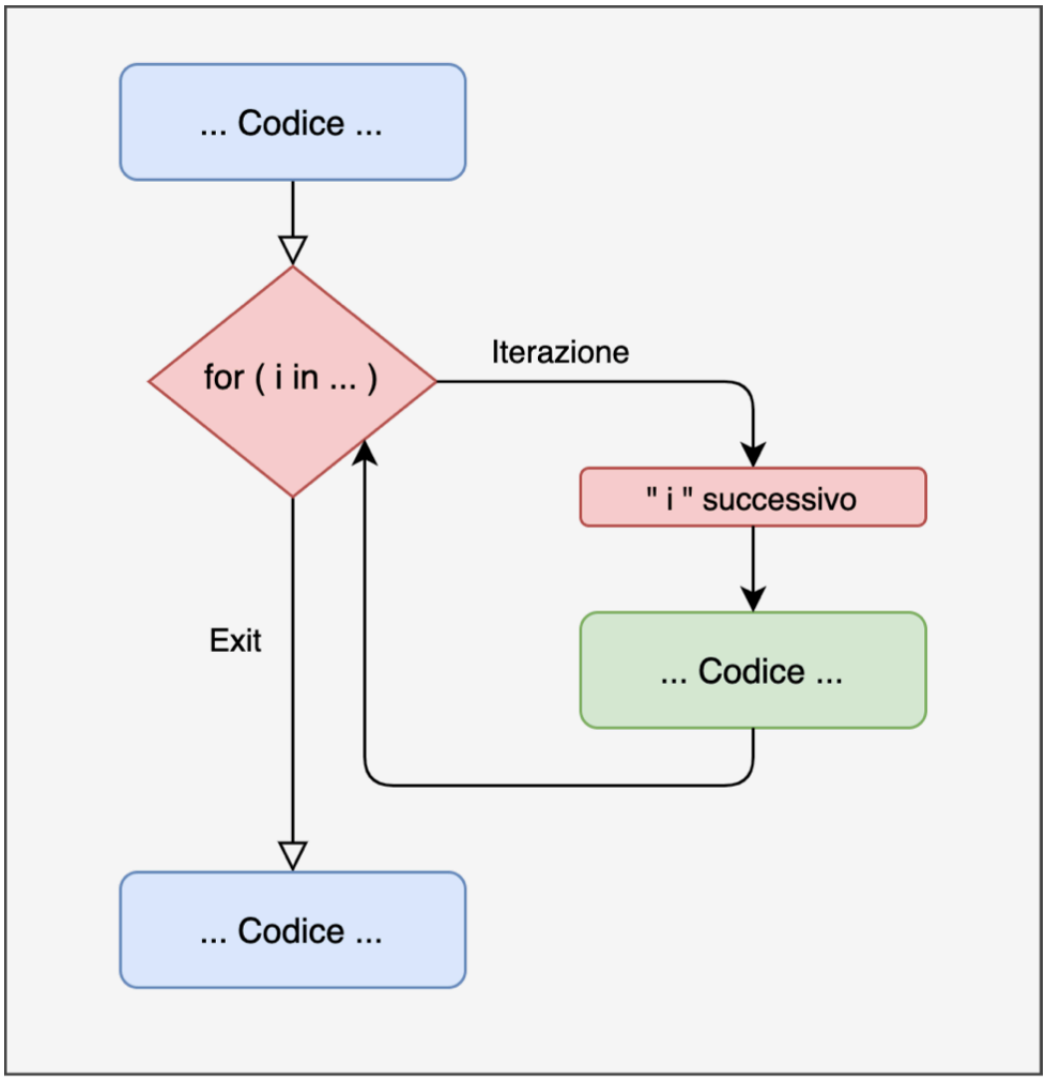

Il ciclo `for` è una struttura che permette di ripetere un numero finito e pre-determinato di volte una certa porzione di codice.

La scrittura di un ciclo for è:

```
n = 10
for(i in 1:n){
# quali operazioni
}
```

Se voglio stampare una cosa 5 volte, posso tranquillamente usare un ciclo for:

```
for(i in 1:5){
print(paste("hello word", i, sep = "_"))
}
```

```
[1] "hello word_1"
[1] "hello word_2"
[1] "hello word_3"
[1] "hello word_4"
[1] "hello word_5"
```

Scomponiamo il ciclo `for`

- `for(){ }`: è l'implementazione in R (in modo simile all'if statement)
- `i`: questo viene chiamato iteratore o indice. E' un indice generico che può assumere qualsiasi valore e nome. Per convenzione viene chiamato i, j etc. Questo tiene conto del numero di iterazioni che il nostro ciclo deve fare
- `in <valori>`: questo indica i valori che assumerà l'iteratore all'interno del ciclo
- `{ # operazioni }`: sono le operazioni che i ciclo deve eseguire

La potenza del ciclo for sta nel fatto che l'**iteratore** i assume i valori del vettore specificato dopo `in`, uno alla volta:

```
for(i in 1:10){
  print(i)
}
```

```
[1] 1
[1] 2
[1] 3
[1] 4
[1] 5
[1] 6
[1] 7
[1] 8
[1] 9
[1] 10
```

`For` con iteratore vs senza

`i` rappresenta l'indice degli elementi del vettore vec

```
vec=1:5

for(i in 1:length(vec)){

  print(vec[i])

  }
```

```
[1] 1
[1] 2
[1] 3
[1] 4
[1] 5
```

`i` rappresenta direttamente ogni elemento del vettore vec

```
vec=1:5

for(i in vec){

  print(i)

}
```

```
[1] 1
[1] 2
[1] 3
[1] 4
[1] 5
```

Ciclo `while`

Il ciclo `while` utilizza una condizione logica e non un iteratore e un range di valori come nel for. Il ciclo continuerà fino a che la condizione è `TRUE`:

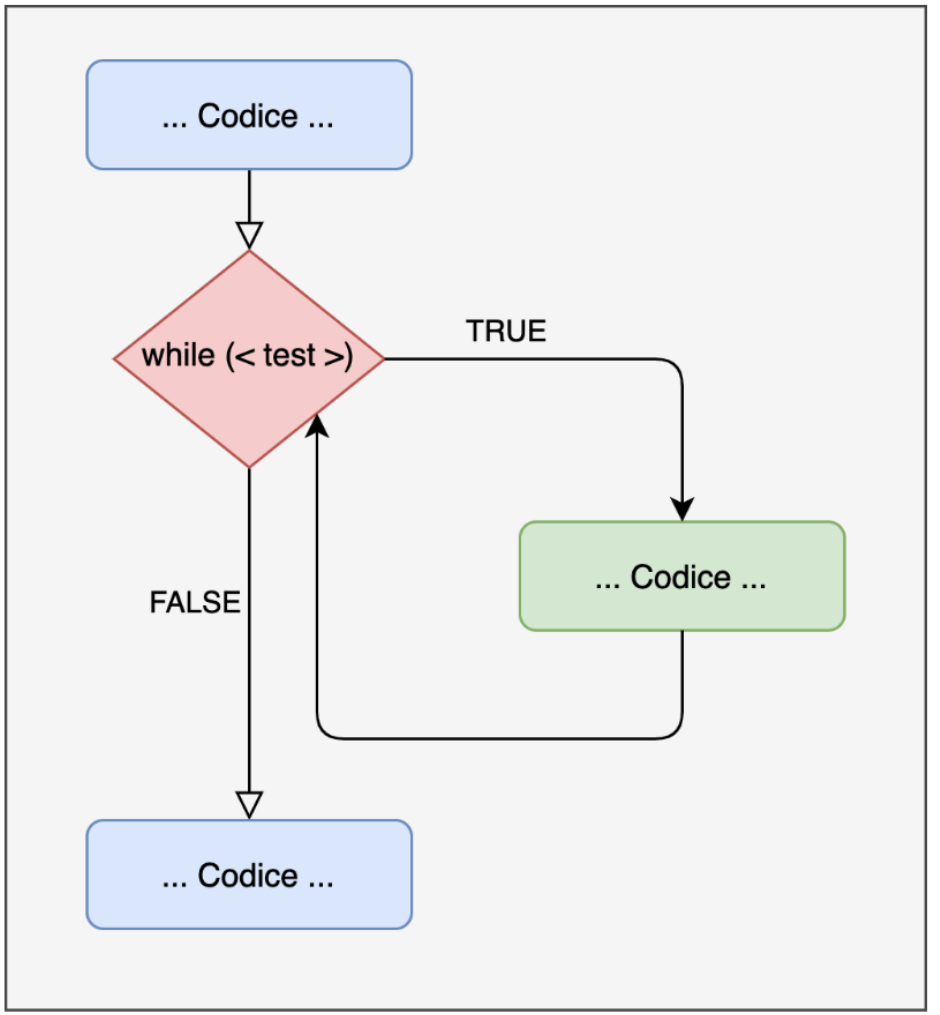

Provate a scrivere questo ciclo `while` e vedere cosa succede e capire perchè accade

```
x = 10

while (x < 15) {

  print(x)

}
```

Il ciclo **`while`** è un ciclo non pre-determinato e quindi necessita sempre di un modo per essere interrotto, facendo diventare la condizione falsa.

```
x = 5

while (x < 15) {
  print(x)
  x = x + 1
}
```

```
[1] 5
[1] 6
[1] 7
[1] 8
[1] 9
[1] 10
[1] 11
[1] 12
[1] 13
[1] 14
```

Ciclo `repeat`

La logica del ciclo `repeat` è molto simile a quella del ciclo `while`, ma con 3 importanti differenze:

1. esegue sempre almeno un’interazione
2. enfatizza la ripetizione fino a che una condizione non viene raggiunta
3. utilizza il comando `break` per terminare

Ciclo `repeat`

Lancia il dado finchè non viene fuori 6:

```
repeat{
  lancia_dado = sample(1:6, 1)
  print(lancia_dado)
  if(lancia_dado == 6) break
}
```

```
[1] 2
[1] 3
[1] 3
[1] 6
```

`repeat` vs. `while`

`repeat` valuta la condizione una volta **finita** l'iterazione, mentre `while` all'**inizio**. Se la condizione non è `TRUE` all'inizio, il while non parte mentre repeat si:

```
i=1
repeat {
  print(i)
  i=i+1
  if(i > 3)break
  }
```

```
[1] 1
[1] 2
[1] 3
```

```
i=1
while (i < 4) {
  print(i)
  i=i+1
  }
```

```
[1] 1
[1] 2
[1] 3
```

Esempio funzione `sum()`

Immaginiamo di non avere la funzione `sum()` e di volerla ricreare, come facciamo?

Idee?

Somma come iterazione

Scomponiamo concettualmente la somma, sommiamo i numeri da 1 a 10:

- prendo il primo e lo sommo al secondo (somma = 1 + 2)
- prendo la somma e la sommo al 3 elemento somma = somma + 3 …

In pratica abbiamo:

- il nostro vettore da sommare
- un oggetto somma che accumula progressivamente le somme precedenti

Somma come iterazione

```
somma = 0 # inizializziamo la somma a 0
x = 1:10 #vettore x

for(i in 1:length(x)){ # per tutta la lunghezza di x = 1:10
  somma = somma + x[i]
}
```

Mettiamo tutto dentro una funzione (i.e., creo una funzione che replichi quello che fa la funzione somma)

```r
my_sum = function(x){
  somma = 0 # inizializziamo la somma a 0
  for(i in seq_along(x)){  # equivalente a 1:length(x)
    somma = somma + x[i]
  }
  return(somma)
}

x = rnorm(100, mean = 0, sd = 1)

my_sum(x)
```

```
[1] 0.6178465
```

```r
sum(x)
```

```
[1] 0.6178465
```

Iterazione, applicazioni

Il ciclo `for` è anche utile per simulare dei dati per esempio. Supponiamo di avere una variabile y (reddito) che dipenda dall'età:

1. Carico il dataset che ho creato:

```r
mydf = read.csv(file = "data/mydf_2.csv") #carico il dataset

str(mydf)
```

```
'data.frame':	30 obs. of  4 variables:
 $ id     : int  1 2 3 4 5 6 7 8 9 10 ...
 $ age    : int  14 30 26 33 45 20 47 17 21 31 ...
 $ age_cat: chr  "adolescente" "giovane" "giovane" "adulto" ...
 $ age_z  : num  -1.625 -0.164 -0.53 0.11 1.205 ...
```

2. Simulo, attraverso un ciclo `for` , la variabile **y** (reddito) assumendo che dipenda da **age_z** (età):

```r
set.seed(111) # per riproducibilità

niter = 1000
res_all = rep(NA, niter)    # tutti gli effetti stimati
p_val = rep(NA, niter)      # tutti i p-value

# Dati osservati
age_z = mydf$age_z
eff_eta = .2 #effetto età
n_obs = length(age_z)

for(i in 1:niter) {
  y = 0 + eff_eta * age_z + rnorm(n_obs, 0, 1) # aggiungo sempre un pò di rumore

  # modello lineare
  mod = lm(y ~ 1 + age_z)

  # estraggo stima effetto
  res_all[i] = coef(mod)[2]

  # p-value di age_z
  p_val[i] = summary(mod)$coefficients[2, 4]
}
```

Risultato:

```r
# Filtra solo risultati significativi
res_sig = res_all[p_val <= 0.05]

# Statistiche descrittive
cat("Proporzione significativi = Power:", mean(p_val <= 0.05), "\n")
```

```
Proporzione significativi = Power: 0.154
```

```r
cat("Media tutti gli effetti:", mean(res_all), "\n")
```

```
Media tutti gli effetti: 0.1875023
```

```r
cat("Media effetti significativi:", mean(res_sig), "\n")
```

```
Media effetti significativi: 0.4612498
```

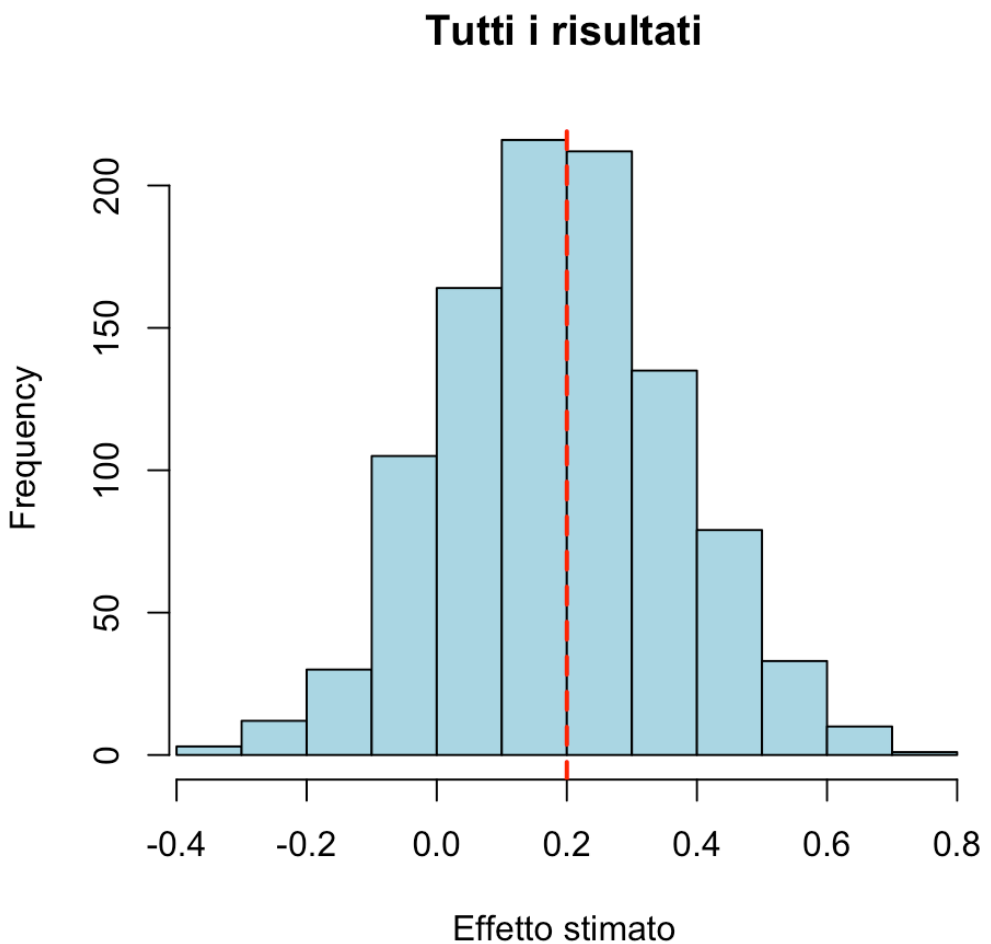
Tutti i risultati
Frequency
0
50
100
150
200
-0.4
-0.2
0.0
0.2
0.4
0.6
0.8
Effetto stimato

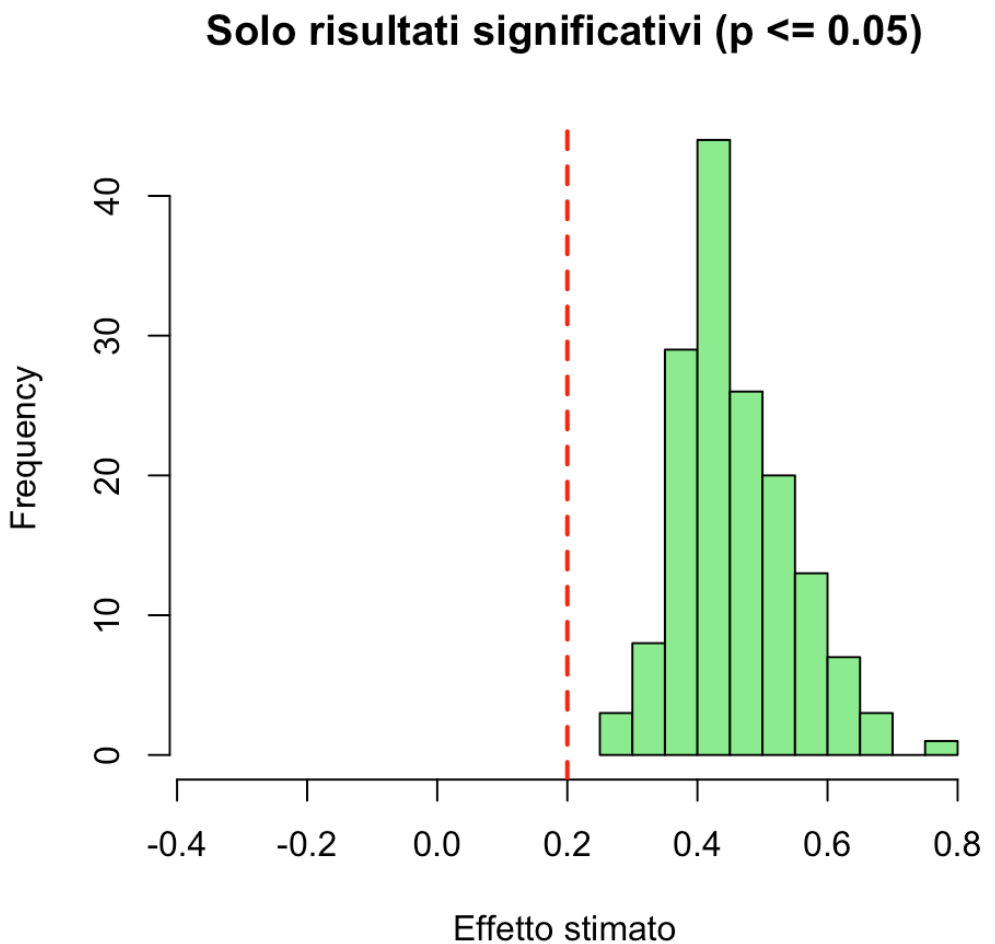
Solo risultati significativi (p <= 0.05)
Frequency
0
10
20
30
40
-0.4
-0.2
0.0
0.2
0.4
0.6
0.8
Effetto stimato

Proprio grazie al for loop è possibile effetuare una ***power simulation***.

Per saperne di più date un’occhiata a questa pagina! :)

Ciclo `for` nested

Una volta compresa la struttura iterativa, si può espandere facilmente inserendo un ciclo dentro un altro:

```
for(i in 1:3){ # livello 1
  for(j in 1:3){ # livello 2
      print(paste(i, j))
  }
}
```

```
[1] "1 1"
[1] "1 2"
[1] "1 3"
[1] "2 1"
[1] "2 2"
[1] "2 3"
[1] "3 1"
[1] "3 2"
[1] "3 3"
```

Immaginiamo di avere due gruppi sperimentali (ad esempio, Gruppo di controllo e Gruppo trattamento), ciascuno con 10 partecipanti. Vogliamo misurare una variabile (ad esempio, il tempo di reazione) per ogni partecipante e registrare i risultati in un dataframe:

```r
# Definire parametri della ricerca
gruppi = c("Controllo", "Trattamento") # Nomi dei gruppi
num_soggetti=10                        # Numero di soggetti per gruppo
tot_soggetti = num_soggetti * length(gruppi)

# Creare un data.frame per memorizzare i dati
res=data.frame(

  # Fattore gruppo
  Gruppo = factor(x = rep(gruppi, each = num_soggetti)),

  # fattore soggetto
  Soggetto = factor(x = 1:tot_soggetti),

  # Tempo di reazione vettore numerico con rt = 0
  RT = numeric(tot_soggetti)
)
```

```r
head(res, 5) # guardo le prime osservazioni di res
```

```
     Gruppo Soggetto RT
1 Controllo        1  0
2 Controllo        2  0
3 Controllo        3  0
4 Controllo        4  0
5 Controllo        5  0
```

```r
tail(res, 5) # guardo le ultime osservazioni di res
```

```
        Gruppo Soggetto RT
16 Trattamento       16  0
17 Trattamento       17  0
18 Trattamento       18  0
19 Trattamento       19  0
20 Trattamento       20  0
```

```r
# Ciclo nested per simulare raccolta dati
set.seed(42)  # Per riproducibilità dei dati simulati

k = 1 #iteratore tempi di reazione

# quanti livelli ha Gruppo?
for (i in 1:length(levels(res$Gruppo))) {

  # inizio con il primo gruppo che è il gruppo di controllo
  gruppo = levels(res$Gruppo)[i]

  for (j in 1:num_soggetti) { # num_soggetti each gruppo

    # è il gruppo di controllo?
    RT = ifelse(gruppo == "Controllo",
                yes = rlnorm(1, mean = log(.500), sd = .050),
                no = rlnorm(1, mean = log(.450), sd = .050))

    res$RT[k] = RT
    k = k + 1
  }
}
```

```r
str(res)
```

```
'data.frame':	20 obs. of  3 variables:
 $ Gruppo  : Factor w/ 2 levels "Controllo","Trattamento": 1 1 1 1 1 1 1 1 1 1 ...
 $ Soggetto: Factor w/ 20 levels "1","2","3","4",..: 1 2 3 4 5 6 7 8 9 10 ...
 $ RT      : num  0.535 0.486 0.509 0.516 0.51 ...
```

```r
head(res, 3)
```

```
     Gruppo Soggetto        RT
1 Controllo        1 0.5354760
2 Controllo        2 0.4860800
3 Controllo        3 0.5091611
```

```r
tail(res, 3)
```

```
        Gruppo Soggetto        RT
18 Trattamento       18 0.3940291
19 Trattamento       19 0.3983075
20 Trattamento       20 0.4807047
```

```r
mean(res$RT[res$Gruppo == "Controllo"])
```

```
[1] 0.5142776
```

```r
mean(res$RT[res$Gruppo == "Trattamento"])
```

```
[1] 0.4476666
```

Ora facciamo un po’ di pratica!

Aprite e tenete aperto questo link:

https://etherpad.wikimedia.org/p/arca-corsoR